

1-5: DBCBD 6-10: ABCAC 11-15: DCCPD
1-6 BD ABD AD ABCD ABC AB
1-4 ✓ ✓ X ✓

4.1 见第6章PPT

最优子集选择, 即对 p 个预测变量的所有可能组合分别使用最小二乘进行拟合

① 记不含预测变量的零模型为 M_0 , 只用于估计各观测的样本均值

② 对于 $k=1, 2, \dots, p$, 拟合 $\binom{p}{k}$ 个包含 k 个预测变量的模型, 在这 $\binom{p}{k}$ 个模型中选择 RSS 最小或 R^2 最大的作为最优模型, 记为 M_k

③ 根据交叉验证模型误差、 C_p (AIC)、BIC 或调整 R^2 从 $M_0, M_1, \dots, M_p$ 个模型中选出一个最优模型

4.2

① 岭回归

$$\min \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$


② Lasso 回归

$$\min \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

③ 光滑样条

$$\min \left\{ \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int (f''(x))^2 dx \right\}$$

4.3



4.4

(1) 记广告收入、平均收入、座椅价格分别为 x_1, x_2, x_3 , 拟合线性回归模型 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$ 后进行 F 检验

F 检验的零假设 H_0 为所有预测变量的回归系数均为 0, 即这些变量对销量没有影响

求出 F 统计量, 如果 F 统计量大于 1 则拒绝 H_0 , 说明至少有一个预测变量显著影响销量; 如果 F 统计量接近 1 则

接受 H_0 , 说明没有预测变量与汽车座椅销量有关

(2) 计算变量的 R^2 统计量, 接近 0 则说明该预测变量与响应变量关系差, 接近 1 则说明关系强

4.5

径向核函数通过衡量样本间的欧氏距离, 在 SVM 起到隐式映射和相似性评估的作用, 从而使模型能够处理非线性问题

$K(x, x_i) = \exp\left(-\sum_{j=1}^p (x_{ij} - x_{ij})^2\right)$ 表示测试点 x 与支持向量 x_i 的相似程度, 如果 x 和 x_i 较近, 则 $K(x, x_i) \approx \exp(0) = 1$, 表明相似度高, 如果 x 和 x_i 较远, 则 $K(x, x_i) \approx \exp(-\infty) \approx 0$, 表明相似度低

$f(x) = \beta_0 + \sum_{i \in S} \hat{\alpha}_i K(x, x_i)$, 如果测试观测距离训练观测距离非常远, 核函数值会很小, 对预测的影响就很小

5.1

(1) 逻辑斯蒂回归、线性判别分析、二次判别分析

(2)

$$ACC = \frac{TP+TN}{TP+TN+FP+FN} = \frac{77+49}{77+49+34+92} = 0.5$$

(3)

$$ACC = \frac{TP+TN}{TP+TN+FP+FN} = \frac{35+106}{35+106+76+35} \approx 0.56$$

(3) ①减少预测变量带来了过拟合的减少

②预测变量之间可能存在共线性

③可能去除了冗余变量

(4) LDA由于其灵活性在训练集上效果更好，而由于贝叶斯决策边界为线性，LDA更接近实际，故在测试集中LDA效果更好

5.2

(1) ①从 Carseats 数据集中随机选取一半作为训练集，剩下的作为测试集

②使用训练集中的所有预测变量构建一颗决策树，并打印决策树的相关信息，同时进行了决策树的可视化

③对测试集应用训练好的决策树模型，求测试集上的均方误差

④使用 `prune.tree` 函数进行剪枝。通过 k 折交叉验证对剪枝的树进行评估，之后绘制两张折线图，第一张用是节点数量和模型偏差的关系图，第二张是 k 与模型偏差的关系图

⑤将决策树修剪为包含 9 个节点的版本，因为在节点数量为 9 时模型偏差最小，然后画出剪枝后的树

(2) 节点数量为 9 的决策树偏差比剪枝前小，但并不知道 MSE 具体是多少，比 4.149 小即可，我猜是 3