

考试后回忆题

仅供参考

1. 下列哪个函数可用来输出矩阵 ()

- A. `sizeof()`
- B. `dim()`
- C. `name()`
- D. `table()`

2. 自由度为8的三次样条结点个数为 ()

- A. 4
- B. 8
- C. 5
- D. 12

3. 在多元线性回归中, 当广告预算被分别使用在两种媒体中时, 模型低估了 sales, 线性回归模型不能准确地反映这种明显的非线性模式。上述现象说明广告媒体间存在 ()

- A. 协同效应
- B. 实验分层原则
- C. 维数灾难
- D. 多重共线性

4. 假设通过最小化以下式子来估计一个线性回归模型中的回归系数: $\sum_{i=1}^n |y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij}|$, $\sum_{j=1}^p |\beta_j| \leq s$,

随着 s 从 0 开始增加, 训练集 ess 会: ()

- A. 最初增长, 然后开始减小, 图像呈现一个倒 U 形.
- B. 最初减小, 然后开始增加, 图像呈现一个 U 形.
- C. 稳定增长
- D. 稳定减小

5. 下列选项中哪一项可用于判断非线性 ()

- A. 方差膨胀因子
- B. 残差图
- C. 相关系数矩阵
- D. 杠杆统计量.

6. `A <- matrix(c(1, 5, 2, 9, 11, 15, 12, 19, 3, 4, 5, 6), nrow=3);`

`B <- matrix(c(4, 7, 8, 10, 25, 29, 26, 23, 44, 52, 77, 80), nrow=3);`

`C <- A+B`

`C[2,3]` 输出结果为 ()

- A. 56
- B. 38
- C. 42
- D. 44

· 写出提升法的 3 个参数及其含义 (6')

2. 观察表 1 和表 2 回答以下问题

	系数	标准差	Z 统计量	P 值
Intercept	-3.5041	0.0707	-49.55	<0.0001
student[CYes]	0.4049	0.1150	3.52	0.0004

表 1

	系数	标准差	Z 统计量	P 值
Intercept	-10.8690	0.4923	-22.08	<0.0001
balance	0.0057	0.0002	24.74	<0.0001
income	0.0030	0.0082	0.37	0.7115
student[CYes]	-0.6468	0.2362	-2.74	0.0062

表 2

① 观察表 1, 为逻辑斯蒂回归模型的系数估计, 说明是否是学生对预测有影响吗? 说明理由.

观察表 2, 为多元逻辑斯蒂回归模型的系数估计, 说明是否是学生对预测有影响吗? 说明理由 (4')

② 根据表中信息, 计算是学生和提学的违约概率 (不用化简也不用计算结果, 写出公式即可) (2')


③ 表 1 和表 2 中的 student [CYes] 系数一正一负, 这种现象称为什么? (2')

3. 下表为 sales 关于 TV, radio 等项的回归模型的最小二乘估计, 模型为 $\hat{y} = \beta_0 + \beta_1 \times TV + \beta_2 \times radio + \beta_3 \times radio \times TV$

	系数	标准差	t 统计量	P 值
Intercept	6.7502	0.248	27.23	<0.0001
TV	0.0191	0.002	12.70	<0.0001
radio	0.0289	0.009	3.24	0.0014
TV x radio	0.001	0.000	20.73	<0.0001

① TV x radio 说明模型具有什么项? 被称为什么作用? 这次能否去掉? 为什么? (4')

② 当 radio 增加一个单位时, TV 如何变化? (2')



如左图为一分类器 (图中点坐标均为整数)

(1) 画出支持向量分类器的最大间隔超平面 (实线), 及其间隔线 (虚线) (2')

(2) 写出最大间隔超平面直线方程 (2')

(3) 写出支持向量 (1')

(4) 加一个点, 记为点 8, 使得两个类别不能被一个超平面分离 (1')

输出四个模型:

模型1: $RSS=1$, $AIC=2.57$, $BIC=2.99$

模型2: $RSS=2$, $AIC=2.0$, $BIC=1.99$

模型3: $RSS=3$, $AIC=0.99$, $BIC=1.01$

根据 RSS , 选择你认为最好的模型, 说明理由(1')

2) 根据 BIC , 选择你认为最好的模型, 说明理由(1')

3) 综合考虑 RSS , AIC , BIC , 考虑实际情况下, 我们应该选择哪个模型, 说明理由.

代码题:

①

library (ISLR)

set.seed(1)

train=sample(392,196)

attach (Auto)

mean ((mpg-predict(lm.fit, Auto))[train]^2)

② set.seed(17)

cv.error.to=rep(0,10)

for(i in 1:10){

glm.fit=glm(mpg~poly(horsepower,i), data=Auto)

cv.error.lo[i]=cv.glm(Auto, glm.fit, k=10)\$delta[i]}

cv.error.10

③ set.seed(14)

alpha.fn(portfolio, sample(100,100, replace=T))

boot(portfolio, alpha.fn, k=1000)

...

1. ①②③代码段分别使用了什么方法来计算测试集误差?

2. 解释 $replace=T$, $k=1000$ 分别代表什么含义

3. 使用①中方法不同的样本集进行训练, 结果相差很大, 说明什么?

4. ②中输出结果如下框, 应选择哪一个来预测模型? 为什么?

☆最后一个代码比较多, 图像也较难画, 在此略。

是装袋法与随机森林代码

问题: ①补充建立测试集与训练集的代码

②判断是分类树还是回归树

(通过图像是 MSE 来判断)

③说明代码投在什么(前是模型和随机森林)

④结果使用哪种方法好, 为什么?

cv.error.10									
24.21	19.19	19.31	19.34	19.18	19.02	19.71	19.90	19.95	20.01