

大连理工大学

姓名 _____
 学号 _____
 院系 _____
 班级 _____
 课序号 _____
 任课教师 _____

课程名称: 高级统计方法 试卷: A 考试形式: 闭卷
 授课部(院): 软件学院 考试日期: 2025年11月30日 试卷共 11 页

	一	二	三	四	五	总分
标准分	30	10	10	30	20	100
得分						

得分

一、单选题 (30 分, 每题 2 分)

1.1 Bayes 公式中, $P(B_i)$ 叫什么?

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

答: [

- A: 似然值
- B: 先验概率
- C: 全概率
- D: 后验概率

1.2 “简单线性回归”中的“简单”是指什么意思?

答: [

- A: 预测变量 X 与响应变量 Y 之间的关系是线性的
- B: X 和 Y 之间的关系是有监督的
- C: 预测变量 X 是一维的
- D: 响应变量 Y 是定量的

1.3 线性回归假设 $y = \beta_0 + \beta_1 x + \epsilon$, 其中随机误差 ϵ 的方差记为 σ^2 , 如何估计 σ ?

答: [

- A: $\sigma = y_i - \hat{y}_i$
- B: $\sigma = (y_i - \hat{y}_i)^2$
- C: $\sigma = \sqrt{RSS/(n-2)}$
- D: $\sigma = RSS/(n-2)$

1.4 线性回归中, 我们经常需要创建哑变量, 以下说法错误的是:

答: [

- A: 哑变量一般用于处理定性的预测变量
- B: 所设置的哑变量作为模型的新的预测变量
- C: 哑变量的个数比相应的定性预测变量的取值个数少 1
- D: 哑变量只能用于多元线性回归中

1.5 线性回归中关于高杠杆点的表述, 下面表述错误的是:

答: [

- A: 它是指观测点 x 是明显异常的点
- B: 如果是多元线性回归, 如果 x 的各个维度都在正常范围, 那么 x 就不是高杠杆点
- C: 相较于离群点, 高杠杆点对回归结果的影响一般比较大
- D: 可以使用杠杆统计量发现高杠杆点

1.6 在预测变量维度 $p > 1$ 的情况下, 线性判别分析 LDA 和二次判别分析 QDA 都假设每一类观测的 $f_k(x)$ 服从一个多元高斯分布, 以下哪一项不正确?

答: [

- A: LDA 假设每一类观测的 $f_k(x)$ 对应的多元高斯分布的均值是不同的
- B: QDA 假设每一类观测的 $f_k(x)$ 对应的多元高斯分布的均值是不同的
- C: LDA 假设每一类观测的 $f_k(x)$ 对应的多元高斯分布的协方差矩阵是不同的
- D: QDA 假设每一类观测的 $f_k(x)$ 对应的多元高斯分布的协方差矩阵是不同的

1.7 在 ξ 处有一个结点的三次回归样条有如下形式, 其中 $(x - \xi)_+^3 = 0 \quad (\forall x \leq \xi)$

$$f(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x - \xi)_+^3$$


结点右侧样条的三次项系数为:

答: [

- A: 0
- B: β_3
- C: β_4
- D: $\beta_3 + \beta_4$

1.8 与下图区域划分对应的决策树有几个内部节点?

答: [



- A: 0
- B: 4
- C: 5
- D: 6

- 1.9 支持向量分类器最大化了软间隔，即最大化允许了一些误分之后的间隔，对所有样本 x_i 满足如下优化描述，请问调节参数 $C=0$ 意味着什么？

$$\begin{aligned} & \underset{\beta_0, \beta_1, \dots, \beta_p, \epsilon_1, \dots, \epsilon_n}{\text{maximize}} \quad M \quad \text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1, \\ & \quad \quad \quad \eta_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M(1 - \epsilon_i), \\ & \quad \quad \quad \epsilon_i \geq 0, \quad \sum_{i=1}^n \epsilon_i \leq C, \end{aligned} \quad \text{答: []}$$

- A: 能容忍穿过软间隔的样本数目为 0
B: 能容忍样本穿过软间隔，但容忍穿过超平面的样本数为 0
C: 支持向量数目为 0
D: 允许样本穿过分割超平面

- 1.10 有时形如支持向量分类器那样的线性边界根本不起作用，可以通过把样本变换包含进来扩大特征空间，以下哪种变换方式不能实现非线性边界？

答: []

- A: X_i^2
B: 多项式核函数
C: 向量内积核函数
D: 径向核函数

- 1.11 随着模型光滑度（flexibility，柔性水平）的增加，模型的方差和偏差会分别？

答: []

- A: 增加、减小
B: 减小、增加
C: 增加、增加
D: 减小、减小

- 1.12 下列关于验证集说法错误的是？

答: []

- A: 验证集随机的把观测集分为两部分：训练集和验证集
B: 验证集错误率一般会高估在整个数据集上拟合模型所得到的测试错误率
C: 测试错误率的验证集法估计的波动很小
D: 验证集方法优点在于原理简单且易于执行

- 1.13 在利用岭回归建立线性回归模型时，随着 λ 从 0 开始增加，模型的偏差会：

答: []

- A: 最初增长，然后开始减小，图像呈现一个倒 U 形
B: 最初减小，然后开始增加，图像呈现一个 U 形
C: 持续增长
D: 持续减小

- 1.14 关于主成分分析 PCA，下列说法错误的是？

答: []

- A: 第一主成分是变量标准化线性组合中方差最大的组合
B: 在进行 PCA 之前，变量应该中心化使均值为零
C: 在不考虑符号变化的情况下，每个主成分载荷向量是不唯一的
D: 主成分分析可以用于数据降维

- 1.15 系统聚类法中，下列那种距离计算方式会发生倒置现象？

答: []

- A: 最长距离法
B: 最短距离法
C: 类平均法
D: 重心法

得分

二、多选题（10 分，每题 2 分）

- 2.1 关于线性回归的表述，下面的表述正确的有

答: []

- A: 是一种监督学习的方法
B: 假定预测变量 X 和响应变量 Y 之间有线性关系
C: 也可用于建模变量 X 和响应变量 Y 之间是非线性关系的情况
D: 响应变量 Y 必须是定量的

- 2.2 关于多元线性回归 $y = \beta_0 + \beta_1 x_1 + \dots + \beta_j x_j + \dots + \beta_p x_p + \epsilon$ ，下面的表述中正确的有：

答: []

- A: 这里做的假设是 x_j 之间是不相关的
B: 也可以使用最小二乘法方法进行系数估计
C: β_j 可解释为在所有其他预测变量保持不变的情况下， x_j 增加一个单位对 y 产生的平均效果

D: 预测变量和响应变量的线性关系同时代表二者之间存在因果关系

2.3 下列哪些模型可以拟合出非线性曲线?

答: [

- A: 三次样条
- B: 自然样条
- C: 局部回归
- D: 光滑样条

2.4 为了提高基于树的方法的预测准确性, 可以组合多棵树, 下列哪些方法属于这个范畴?

答: []

- A: 随机森林
- B: 装袋法
- C: 提升法
- D: 代价复杂性剪枝

2.5 对包含 1000 个样本的数据集进行 k 折交叉验证, 下列说法错误的是?

答: []

- A: 当 $k=10$ 时, 每次用 100 个样本拟合模型
- B: k 折交叉验证采用有放回抽样的方法构造 k 个规模大致相同的数据集
- C: 与 $k=10$ 相比, 当 $k=1000$ 时所产生的测试误差估计的方差要更大
- D: k 折交叉验证划分的 k 份数据是可以有交集的

得分

三、判断题 (10 分, 每题 2 分)

3.1 线性回归中, 使用多个数据集拟合时, 所得到的拟合结果是相同的。

答: []

3.2 本质上, 线性判别分析 LDA 是贝叶斯分类器的在特殊场景下的化简。

答: []

3.3 对于所有二分类样本的情况, 一定都能找到分割超平面将样本按类别分开。

答: []

3.4 P 作为响应变量 Y 的预测, 其精确性依赖于可约误差和不可约误差。

答: []

3.5 每个观测被随机分配到的初始类, 对 K 均值聚类算法的结果没有影响。

答: []

得分

四、简答题 (30 分, 每题 6 分)

4.1 Advertising 数据集是一个探究 TV、radio 和 newspaper 三种广告投放与销量 sales 之间关系的数据集; 我们校验了 sales 和 newspaper 之间的关系, 得到如下所示的结果。

Simple regression of sales on newspaper

	Coefficient	Std. error	t-statistic	p-value
Intercept	12.351	0.621	19.88	< 0.0001
newspaper	0.055	0.017	3.30	< 0.0001

1) 请回答 newspaper 和 sales 之间有无关系, 为什么? (2 分)

2) 如果此时 newspaper=1000, 其对应 sales 的估计值为多少 (需给出计算公式和计算结果)? (2 分)

3) 请写出 newspaper 变量所对应系数的 95% 置信区间的计算公式和计算结果。(2 分)

4.2 以 Credit 数据集为例, 我们希望建立从收入 income 和学生 student 两个预测变量预测债务 balance 的回归模型。请回答以下问题。

1) 请写出模型的数学表达式，并进一步化简得到是学生和不是学生的表达式，其中：请将 income 设定为第一个预测变量，将 student 设置为第二个预测变量。（2分）

2) 在你所写出的模型中，请回答：用哪个参数来衡量学生和非学生的平均债务差异。（2分）

3) 假设收入 income 和学生 student 有交互作用，请写出模型的数学表达式，并进一步化简得到是学生和不是学生的表达式。其中：请将 income 设定为第一个预测变量，将 student 设置为第二个预测变量。（2分）

4.3 假设通过最小化以下式子来估计一个线性回归模型中的回归系数：
 $\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2$, $\sum_{j=1}^p |\beta_j| \leq s$, s 为某给定值。则随着 s 从 0 开始增加，拟合的模型在训练集的偏差（2分）、训练集的方差（2分），以及测试集的均方误差（2分），请说明分别呈现怎样的变化。

4.4 已知一维空间有五个数据点，分别是 $X_1=1$, $X_2=4$, $X_3=5$, $X_4=7$, $X_5=11$ 。试用 K 均值聚类方法将它们划分为两类。请描述出具体计算过程，并给出最终聚类结果。假设初始类为 $G_1^{(0)} = \{X_1, X_3\}$ 和 $G_2^{(0)} = \{X_2, X_4, X_5\}$ 。（6分）

4.5 光滑样条函数 $g(x)$ 拟合某些数据的准则如下，其中 λ 是一个非负的调节参数，请描述 1) $\lambda=0$ ，以及 2) $\lambda \rightarrow \infty$ ，对函数 g 的影响。（每项 3 分）

$$\underset{g \in \mathcal{S}}{\text{minimize}} \sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int g''(t)^2 dt$$

损失函数

波动性惩罚

得分

五、编程计算题（20 分，每题 10 分）

5.1 Default 数据集包含了一系列信用卡违约人群的信息，是典型的分类任务的数据集。假设如下所示是某分类算法在某独立测试集上的性能表现。

		真实违约情况		
		没有	有	共计
预测违约情况	没有	6400	1500	7900
	有	1600	500	2100
	共计	8000	2000	10000

1) 在分类算法的性能评价中，本矩阵被称为什么矩阵？（2分）

2) 请给出本算法总体错误率的计算公式 (使用 TP, TN, FP, FN 中的一个或多个进行表达) 及最终计算结果 (2 分)

3) 请给出预测阳性率的计算公式 (使用 TP, TN, FP, FN 中的一个或多个进行表达), 并给出本算法的预测阳性率 (代入数字即可)。(2 分)

4) 假设本算法非常稳定 (即: 真阳性率、假阳性率、真阴性率、假阴性率均保持不变), 如果在另一个 3000 人的测试集上 (包含 1000 个违约人, 2000 个未违约人) 进行测试, 那么:
大约有多少违约的人会被成功检测出来, 请给出公式及最终计算结果 (2 分);
大约有多少未违约的人会被错判为违约, 请给出公式及最终计算结果 (2 分)。

5.2 用提升法在 Hitters 数据集上预测 Salary 的代码如下。请回答下列问题: (注意, 下面的代码是连续的, a-e 用花括号括起来标记只是方便提问, 不是代码。另外, 请在每小题目于后空白处作答, 不要在代码处作答)
1) a、b、c 代码段都在做什么? (2+2+2=6 分)

2) 请回答输出位置 d 处的大致结果。(2 分)

3) 请用一句话指出 e 这段代码在使用什么模型 (1 分)。跟提升法的结果比较哪个好? (1 分)

```
## 代码:
library(ISLR)
sum(is.na(Hitters$Salary))

a{
  train = 1:200
  Hitters.train = Hitters[train,]
  Hitters.test = Hitters[-train,]
}

library(gbm)

set.seed(103)
pows = seq(-10, -0.2, by = 0.1)
lambdas = 10^pows
length.lambdas = length(lambdas)
train.errors = rep(NA, length.lambdas)
test.errors = rep(NA, length.lambdas)
for (i in 1:length.lambdas){
  b{
    boost.hitters = gbm(Salary ~ ., data = Hitters.train, distribution = "gaussian",
      n.trees = 1000, shrinkage = lambdas[i])
  }
}
```