

对于 $f(x)$ 的估计 $\hat{f}(x)$ 有 $E[(Y - \hat{f}(x))^2 | X=x] = E[f(x) - \hat{f}(x)]^2 + \text{Var}(e)$

均方误差 $MSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ (k折交叉验证则为 $\frac{1}{n} \sum_{k=1}^K MSE_k = \frac{\text{可约误差}}{n} + \frac{\text{不可约误差}}{nK}$)

线性模型

1. XX 与 XX 有关吗 $\rightarrow \beta$ 扣且 $p < 0.05$ (观测值 > 1 相关, $t = z = \frac{\beta}{SE(\beta)}$) $p < 0.001$ 显著相关, 拒绝 H_0

2. XX 与 XX 关系多强 $\rightarrow R^2 = 1 - \frac{RSS}{TSS}$ (近越好)

3. 哪个 XX 能促进 $XX \rightarrow \beta > 0$ 的

4. 精确估计 XX 对 XX 影响 $\rightarrow \beta$ 置信区间 $(95\% = \beta_0 \pm 2SE(\beta_0))$ $SE(\beta_i)^2 = \frac{\sigma^2}{\sum (x_i - \bar{x})^2} \rightarrow$ 估计响应值

5. 预测的精度评价 $\rightarrow RSE / R^2 / MSE$ ($RSE = \sqrt{\frac{1}{n-1} RSS}$ 越小越好)

6. 判断是否线性 $\rightarrow$ 残差图 (杂乱线性) $\dots$ 线性残差 $= \frac{e_i}{SE}$

7. 协同效应 $\rightarrow$ 交互系数为不为 0

8. β 是否全 0 $\rightarrow F = \frac{(TSS - RSS)/p}{RSS/(n-p-1)}$ ($F >$ 临界值, 拒绝原假设)

① $Y = \beta_0 + \beta_1 x_1 + e$

令 RSS 最小求得 $\beta_1 = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2}$
 $\beta_0 = \bar{y} - \beta_1 \bar{x}$

② $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + e$

β_j 为其他所有变量不变情况下, x_j 对 Y 的斜率

假设 X 与 Y 关系线性

误差项方差恒定, 不相关 (相关则低估真实标准误差)

③ 逻辑斯谛 $p(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$

$\ln \frac{p}{1-p} = \beta_0 + \beta_1 x$

估计 $\beta =$ 极大似然估计 $l(\beta_0, \beta_1) = \sum \ln(p(x_i)) + \sum \ln(1-p(x_i))$

多元 logistic 可以发现混淆现象

④ 贝叶斯分类器

$P(Y=k | X=x) = \frac{\lambda_k f_k(x)}{\sum \lambda_k f_k(x)}$ (λ 先验概率, f 密度函数)

⑤ LDA =

假设 $\sigma_1^2 = \dots = \sigma_k^2 = \sigma^2$ $P=1, P>1$ 则协方差阵相同

$P_k(x) = \frac{\lambda_k \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}(\frac{x-\mu_k}{\sigma})^2}}{\sum \lambda_k \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}(\frac{x-\mu_k}{\sigma})^2}}$

$\downarrow$

$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\lambda_k)$

估计 $\hat{\lambda}_k = \frac{n_k}{n}, \hat{\mu}_k = \frac{1}{n_k} \sum x_i$

$\hat{\sigma}_k^2 =$

$\therefore p_i = \frac{e^{\delta_i(x)}}{\sum e^{\delta_i(x)}}$

ROC 曲线下面积 AUC ↑ 分类器越好

$\rightarrow$ 对模型影响不大

离群点: y_i 异常 高杠杆点: x_i 异常

验证集错误率 高 测试误差

交叉验证 (测试误差偏高 (数据少 拟合差))

留法法 偏差小 方差大

自助法 约用了 $\frac{2}{3}$ 的数据

① 岭回归 (基于线性模型加了惩罚项)

$RSS' = RSS + \lambda \sum_{j=1}^p \beta_j^2 = \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2$

λ 从 $0 \rightarrow \infty, \beta$ 从 $\infty \rightarrow 0$ $\hat{\beta}_j = \frac{\beta_j}{1+\lambda}$ $\lambda > 0$

($\lambda \rightarrow \infty \rightarrow 0$) 训练 $RSS \uparrow$; 测试 RSS 后大
偏差 $\downarrow$; 偏差 $\uparrow$; 不可约误差 =

⑧ LASSO 回归 β 可到 0

$RSS' = RSS + \lambda \sum_{j=1}^p |\beta_j|$

1. 最优子集选择:

拟合 (k) 个含 k 个变量模型

选 RSS 最小 / R^2 最大

用交叉验证选 $C_p(AIC)$, BIC 或 R^2 选最优

缺点: 计算效率低, 预测能力弱

过拟合和参数估计方差高

2. 向前逐步

零模型 M_0

每次加一个变量, 选择

选 RSS / R^2

交叉验证 C_p BIC R^2 选最优

缺点: 无法最优 虽然运算效率高

3. 向后逐步

全模型 M_p

每次减一个变量, 选择

选 RSS / R^2

交叉验证

缺点: 无法最优

满足 $n > p$

估计测试误差: (d 就是选多少个变量)

$$C_p = \frac{1}{n} (RSS + 2d\hat{\sigma}^2)$$

$$AIC = \frac{1}{n\hat{\sigma}^2} (RSS + 2d\hat{\sigma}^2)$$

$$BIC = \frac{1}{n} (RSS + \log(n) d\hat{\sigma}^2)$$

单位

$$\text{调整 } R^2 = 1 - \frac{RSS/(n-d-1)}{TSS/(n-1)} \rightarrow \text{最高}$$

④ 最大间隔分类器

$$\sum \beta_i = 1$$

$$y_i (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) > M$$

求每个平面的间隔最小

然后每个最小中选最大的

$$y_i (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) > M(1 - \epsilon_i)$$

$$\epsilon_i > 0, \sum \epsilon_i \leq C \Rightarrow \text{最多 } C \text{ 个违规}$$

⑤ 线性支持向量分类器

$$f(x) = \beta_0 + \sum_{i=1}^n \alpha_i \langle x, x_i \rangle$$

多项式:

$$f(x) = \beta_0 + \sum \alpha_i k(x, x_i)$$

$$k = (1 + \sum_{j=1}^p x_{ij} x_{ij})^d$$

(展开有 $\binom{p+d}{d}$ 项)

核函数:

$$f(x) = \beta_0 + \sum \alpha_i k(x, x_i)$$

$$k = \exp(-\gamma \sum_{j=1}^p |x_{ij} - x_{ij}|)$$

① 回归树 (图画树必)

找分割点 s 使两边 $x_j < s$ 和 $x_j \geq s$

的 RSS 尽可能小

一直找, 左右终端为均值

树终端结点数

$$\text{剪枝} = RSS' = \sum_{i=1}^n \sum_{j \in R_m} (y_i - \hat{y}_{R_m})^2 + d ||L||$$

⑤ 提升法 (回归树)

$$\hat{f}(x) = 0, y_i = y_i$$

重复 B 次 (B 棵树)

对 (x, y) 建 d 个分裂点的树 $\hat{f}^b$ ($d+1$ 个终端)

$$\hat{f}(x) = \hat{f}(x) + \hat{f}^b(x)$$

$$\therefore \hat{f}(x) = \sum_{b=1}^B \lambda \hat{f}^b(x)$$

② 分类树

与回归树类似, 只把 RSS 换成

$$\text{分类错误率 } E = 1 - \max_k (\hat{p}_{mk})$$

不好, 换

$$\text{基尼系数 } G = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk})$$

$$\text{互熵 } D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

③ 集成法 =

自助取 B 个集

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^b(x)$$

取平均可降低方差

集外观测值有 $\frac{1}{B}$

自助验证集

④ 随机森林 =

自助取 B 个集

但建树不常规, 每个节点

选择从 m ($m \leq p$) 个中选

最优

缺点: 树准确性不高

D主成分分析

数据中心化处理 $\Rightarrow$ 均值为0

找一条线方差 = $\frac{1}{n} \sum_{i=1}^n z_i^2$ 最大, 重复找线为

$$z = \varphi_1 x_1 + \varphi_2 x_2 + \dots + \varphi_p x_p, \sum \varphi^2 = 1$$

$$\text{最后 } PVE = \frac{\sum_{i=1}^n z_i^2}{\sum_{i=1}^n \sum_{j=1}^p x_{ij}^2} \quad \text{判断留几个成分}$$

第一主成分: p 维空间中最近 n 个观测点的线)

② K均值聚类 (类内差异最小)

$$\min (c_1, \dots, c_k) \left\{ \sum_{k=1}^k \sum_{i \in c_k} (x_{ij} - x_{kj})^2 \right\}$$

每个点随机属于一类

每类中心计算

每个点和类中心欧式距离计算, 归最近类

重新找类中心

③ 系统聚类


每次找最近的两个

最长距离法

最短距离法

类平均法

重心法 $\rightarrow$ 例置



代码:

lm() 最小二乘线性回归拟合

{ fix() 打开数据编辑器 names() 查变量名
summary() coef() 系数提取
confint() 默认95%置信区间, predict() interval = confidence
interval = prediction

glm() 分类逻辑回归, family = binomial

lda() 线性判别分析 qda() = 二次判别分析

glmnet() { alpha = 0 岭回归
alpha = 1 Lasso

randomForest() 装袋法 & 随机森林 mtry = n (装袋, p 为随机森林) importance = 变量重要性

gbm() 提升法, distribution = gaussian 回归 (分类用 bernoulli), shrinkage 学习率

SVM() 支持向量机, kernel = linear 线性, radial 径向核, cost 越小 / C 越大 间隔越宽
tune() 交叉验证调优

dist() 欧式距离矩阵

hclust() 系统聚类 method = complete, single, average, centroid